

Homework-1 (Chapter 3. Classification)

110321006 蔡秉翰

110321007 劉竑毅

為了使用 `SGDClassifier` 進行 MNIST 數據集的多類別分類，首先進行資料的初步整理，將 70000 筆資料分成了 60000 和 10000，其中 60000 用來訓練模型，10000 用來測試，先用 `SGDClassifier` 訓練出模型後，使用交叉驗證評估模型性能（`cv=3`）來測量準確性，最後在 10000 筆資料的測試集上進行測試得到了以下結果

```
Cross-Validation Scores: [0.87365 0.85835 0.8689]
Mean Accuracy: 0.8669666666666668
Test Set Accuracy: 0.874
```

訓練集平均交叉驗證和測驗集準確率差不多，可能代表資料平均，訓練得很好，測試集準確率也有到 87，有機會可以更好，以下是 confusion matrix


```
Confusion Matrix:
[[ 902    0     8    11     1    13     2     4    39     0]
 [  0 1095     2     3     0     2     4     1    28     0]
 [  1    10   803    69     6     4     4    10   122     3]
 [  0     1     6   931     1    21     3     7    35     5]
 [  2     2     9    15   778     4     2     9    62   99]
 [  6     2     1    71     3   709     12    12    67     9]
 [  5     3    12    13     5    21   854     0    45     0]
 [  0     3    18    20     3     4     1   919    18   42]
 [  3     5     2    30     4    43     5     5   872     5]
 [  3     5     2   33     7     5     0    20    57  877]]
```

將訓練資料除以 255，進行 normalization，訓練模型的時間大大的縮短，然後準確率也明顯的提高到 0.91

```
Cross-Validation Scores: [0.90195 0.89985 0.90695]
Mean Accuracy: 0.9029166666666667
Test Set Accuracy: 0.9174
```

Confusion Matrix:

```
[[ 956     0     2     2     0     3    12     3     1     1
   [     0 1112     3     1     0     3     5     1    10     0
   [     8     5 934    13     6     2    14    13    33     4
   [     5     0    26 902     2    30     3    13    21     8
   [     1     3     5     0 888     0    20     5     8    52
   [    12     3     1    24    12 777    24     5    27     7
   [     7     3     6     2     6     7 925     0     2     0
   [     2     8    23     3     7     1     1 949     3    31
   [    12    12     8    17    15    38    11    14 834    13
   [    10     8     2    17    28    12     0    27     8 897]]
```



由 confusion matrix 可以看出在 2 的表現比在其他數字上的表現
更好

到了第二小題，我們使用人工成長訓練集來測試看看是否可以
提高準確性，我們將 60000 筆 normalization 用來訓練的資料，利用
系統的 `scipy.ndimage` 內的 `shift` 函數位移了上左右下各一份副本然後


合併到新的訓練集，標籤也是放入新的訓練集，依舊用 10000 個原始資料做測試，得到了以下結果

```
Cross-Validation Scores: [0.89107 0.85614 0.83964]
Mean Accuracy: 0.8622833333333334
Test Set Accuracy: 0.9193
```

可以看到準確率稍微的提升從 0.9174 上升到 0.9193 提升是微乎其微的

Confusion Matrix:

```
[[ 968     0     0     2     1     2     5     1     1     0
   [  0 1123     2     3     0     1     4     1     1     0
   [ 10     7 916     7    15     4    11    23    34     5
   [  4     2    23 901     2    31     2    17    20     8
   [  1     5     3     0 922     0     8     2     4    37
   [ 10     7     1    27    13 781     19    11    18     5
   [ 12     3     3     1     9    18 910     0     2     0
   [  4    13    17     2     8     0     0    962     0    22
   [ 16    14     7    10    21    39    13    22 823     9
   [ 14     7     0    10    33    12     1    41     4 887]]]
```



`SGDClassifier` 的 normalization 或超參數調整 ，可以讓模型的準確率上升

使用 `SGDClassifier` 進行 Fashion MNIST 數據集的多類別分類，首先將 70000 筆資料分成了 60000 和 10000，其中 60000 用來訓練模型，10000 用來測試，先用 `SGDClassifier` 訓練出模型後，使用交叉驗證評估模型性能（`cv=3`）來測量準確性，最後在 1000 筆資料的測試集上進行測試

```
Cross-Validation Scores: [0.78315 0.81355 0.82255]  
Mean Accuracy: 0.8064166666666667  
Test Set Accuracy: 0.8014
```

訓練集平均交叉驗證和測驗集準確率幾乎一致，相較於一開始的 MNIST 數據集，Fashion MNIST 的 Cross-Validation Scores 三項都比較低，感覺是圖案比較複雜，，以下是 confusion matrix

Confusion Matrix:


```
[[666 12 11 70 11 0 203 0 24 3]
 [ 2 959 0 24 4 0 7 1 3 0]
 [ 5 8 494 11 152 0 301 0 29 0]
 [ 7 33 13 833 38 0 58 1 16 1]
 [ 0 3 46 30 699 0 201 0 21 0]
 [ 3 3 4 0 0 816 1 66 41 66]
 [ 92 5 49 45 77 0 689 0 42 1]
 [ 0 0 0 0 0 12 0 932 4 52]
 [ 1 1 0 6 1 4 19 5 963 0]
 [ 1 0 0 0 0 3 1 30 2 963]]
```

將訓練資料除以 255，進行 normalization，準確率提升到了 0.82

```
Cross-Validation Scores: [0.8444 0.8359 0.8435]
Mean Accuracy: 0.8412666666666667
Test Set Accuracy: 0.8231
```

Confusion Matrix:

```
[[663 5 38 159 2 3 113 0 17 0]
 [ 3 954 4 32 2 0 3 0 2 0]
 [ 9 3 787 24 80 0 83 1 13 0]
 [ 8 10 12 932 12 0 19 0 7 0]
 [ 0 6 174 80 620 0 109 0 11 0]
 [ 2 0 1 4 0 911 3 45 14 20]
 [ 78 4 157 111 52 0 559 0 39 0]
 [ 1 0 0 0 0 32 0 941 1 25]
 [ 2 1 5 17 1 6 13 4 951 0]
 [ 0 1 0 3 0 26 4 53 0 913]]
```




可以看到錯誤集中在 236 行

到了第二小題，我們使用人工成長訓練集來測試看看是否可以提高準確性，得到了以下結果

```
Cross-Validation Scores: [0.80176 0.75582 0.74984]
Mean Accuracy: 0.76914
Test Set Accuracy: 0.8298
```

跟一開始差不多，準確率來到 0.8298， confusion matrix

Confusion Matrix:											
819	6	24	67	6	3	61	0	14	0		
5	945	6	31	6	0	4	1	2	0		
19	4	696	15	153	0	102	1	10	0		
22	17	12	878	28	0	39	0	4	0		
1	3	79	47	750	0	110	0	10	0		
3	1	1	3	0	875	0	85	11	21		
190	5	118	65	87	0	505	0	29	1		
0	0	0	0	0	18	0	969	0	13		
6	1	5	12	4	4	20	6	942	0		
0	0	1	2	0	10	0	67	1	919		



可以看到第二行和第三行的錯誤減少了很多但是第一行增加了一點

以我的實驗去做結論的話，我認為 `SGDClassifier` 在第一個資料集上的效能比較好，在 `Fashion MNIST` 資料及上效果較差在， 2 個資料集在 `normalization` 之後性能就已經提升很多了的，而資料加強在兩個資料集上都沒有取得卓越的效果，我的結論是資料加強可能效果有限，僅限於如果我的實驗是正確的，以上是功課一的報告內容，感謝觀看