

# Homework-1 (Chapter 3. Classification)

110321006 蔡秉翰

110321007 劉竑毅

為了使用 SGDClassifier 進行 MNIST 數據集的多類別分類，首先我們使用 GOOGLE 的 COLAB 開啟了專案，下載了 MINST 的資料集，並進行資料的初步整理，將 7000 筆資料分成了 6000 和 1000，其中 6000 用來訓練模型，1000 用來測試，先用 SGDClassifier 訓練出模型後，使用交叉驗證評估模型性能（cv=3）來測量準確性，最後在 1000 筆資料的測試集上進行測試得到了以下結果

```
Cross-Validation Scores: [0.87365 0.85835 0.8689]
Mean Accuracy: 0.8669666666666668
Test Set Accuracy: 0.874
```

訓練集平均交叉驗證和測驗集準確率差不多，可能代表資料平均，訓練得很好，測試集準確率也有到 87，有機會可以更好，以下是 confusion matrix

```
Confusion Matrix:
[[ 902    0     8    11     1    13     2     4    39     0]
 [  0 1095     2     3     0     2     4     1    28     0]
 [  1    10   803    69     6     4     4    10   122     3]
 [  0     1     6   931     1    21     3     7    35     5]
 [  2     2     9    15   778     4     2     9    62   99]
 [  6     2     1    71     3   709    12    12    67     9]
 [  5     3    12    13     5    21   854     0    45     0]
 [  0     3    18    20     3     4     1   919    18   42]
 [  3     5     2    30     4    43     5     5   872     5]
 [  3     5     2    33     7     5     0    20    57  877]]
```

感覺是 3 和 8 很容易誤判，可能需要修正資料集的錯誤

到了第二小題，我們使用人工成長訓練集來測試看看是否可以提高準確性，我們將 6000 筆用來訓練的資料，利用系統的 `scipy.ndimage.interpolation` 內的 `shift` 函數位移了上左右下各一份副本然後合併到新的訓練集，標籤也是放入新的，依舊用 1000 個原始資料做測試，然而我忘了將原始的訓練資料也放入，訓練一次模型要很久，尤其是交叉驗證，所以我放棄加入原始資料的想法了，訓練集維持為四份位移過的副本，所以應該會有大誤差，最後，得到了以下結果

```
Cross-Validation Scores: [0.81533 0.78999 0.80644]  
Mean Accuracy: 0.8039200000000001  
Test Set Accuracy: 0.8696
```

這結果反而不如原始數據，所以我決定重新用原始數據加上四個副本重新訓練模型，又要消耗兩個小時，以下是 confusion matrix

```
Confusion Matrix:  
[[ 968   0   0   2   0   3   5   1   1   0]  
 [  0 1118   1   6   0   2   7   0   1   0]  
 [ 15   4  875   71   2   9   25   5  22   4]  
 [  7   3  21  891   1  41   8  16  16   6]  
 [  6   7  19   2  811   11  20   5   4  97]  
 [ 12  10   9  79   4  731  17   6  19   5]  
 [ 46   4  16   1   3  22  866   0   0   0]  
 [ 10  15  42   8   1   5   3  908   0  36]  
 [ 24  38  19  49  14  93  24  16  658  39]  
 [ 19  10   5  19  16  27   1  37   5  870]]
```

雖然 Test Set Accuracy 有到 86，但使還是低於 87，這不應該，可能


是因為我一開始忘了加原始數據導致的

又重新做了一次，將五份副本轉換為 NumPy 數組，以便進行後續的模型訓練，結果是輸出和四份副本一模一樣，我開始懷疑人生，我也不知道為什麼會一模一樣


```
Cross-Validation Scores: [0.81533 0.78999 0.80644]  
Mean Accuracy: 0.8039200000000001  
Test Set Accuracy: 0.8696
```

得到的 MATRIX

```
Confusion Matrix:  
[[ 968     0     0     2     0     3     5     1     1     0]  
 [   0 1118     1     6     0     2     7     0     1     0]  
 [  15     4  875    71     2     9    25     5    22     4]  
 [   7     3   21  891     1    41     8    16    16     6]  
 [   6     7   19     2   811    11    20     5     4    97]  
 [  12    10     9   79     4   731    17     6    19     5]  
 [  46     4   16     1     3    22   866     0     0     0]  
 [  10    15   42     8     1     5     3   908     0    36]  
 [  24    38   19    49    14    93    24    16   658    39]  
 [  19    10     5   19    16    27     1    37     5   870]]
```



左邊是原始的，右邊是資料加強後的，加強資料後的看起來比較好，但是數值上準確率比較差，僅限於我的實驗結果



左邊是原始的，右邊是資料加強後的  
`SGDClassifier` 的標準化或超參數調整 ，可以讓模型的準確率上升，例如 `Standard Scaler ()`、選擇適當的損失函數、調整學習率和正則化、使用交叉驗證來評估模型性能，並選擇最佳的超參數組合，但因為時間有限我沒有做，第一題就到此為止。

使用 SGDClassifier 進行 Fashion MNIST 數據集的多類別分類，首先我們使用 GOOGLE 的 COLAB 開啟了專案，下載了 Fashion MNIST 的資料集，並進行資料的初步整理，將 7000 筆資料分成了 6000 和 1000，其中 6000 用來訓練模型，1000 用來測試，先用 SGDClassifier 訓練出模型後，使用交叉驗證評估模型性能（cv=3）來測量準確性，最後在 1000 筆資料的測試集上進行測試

```
Cross-Validation Scores: [0.78315 0.81355 0.82255]  
Mean Accuracy: 0.8064166666666667  
Test Set Accuracy: 0.8014
```

訓練集平均交叉驗證和測驗集準確率幾乎一致，訓練得很好，相較於一開始的 MNIST 數據集，Fashion MNIST 的 Cross-Validation Scores 三項都比較低，感覺是圖案比較複雜，性能還可以，但可以再加強，以下是 confusion matrix

```
Confusion Matrix:  
[[666 12 11 70 11 0 203 0 24 3]  
 [ 2 959 0 24 4 0 7 1 3 0]  
 [ 5 8 494 11 152 0 301 0 29 0]  
 [ 7 33 13 833 38 0 58 1 16 1]  
 [ 0 3 46 30 699 0 201 0 21 0]  
 [ 3 3 4 0 0 816 1 66 41 66]  
 [ 92 5 49 45 77 0 689 0 42 1]  
 [ 0 0 0 0 0 12 0 932 4 52]  
 [ 1 1 0 6 1 4 19 5 963 0]  
 [ 1 0 0 0 0 3 1 30 2 963]]
```

到了第二小題，我們使用人工成長訓練集來測試看看是否可以提高準確性，然而我的代碼和一開始一樣沒注意到，忘了加入原始數據最後，得到了以下結果

```
Cross-Validation Scores: [0.75881 0.68715 0.73772]
Mean Accuracy: 0.7278933333333333
Test Set Accuracy: 0.7365
```

這下比一開始更低了，準確率跌到剩下 73%，我不太懂哪裡錯了也許是忘了加入原始數據最後，所以我也決定要重做，以下是 confusion matrix，

```
Confusion Matrix:
[[648   4   11  313   5   2   7   0   10   0]
 [ 6 835   6 146   5   0   1   0   1   0]
 [ 55   3 443 149 344   0   6   0   0   0]
 [ 8   4   1 974   8   0   3   0   2   0]
 [ 3   1   24 144 812   0  16   0   0   0]
 [ 4   0   0   19   0 881   0  65   8  23]
 [174   2   67 297 338   0 108   0  14   0]
 [ 1   0   0   0   0  24   0 878   0  97]
 [ 38   1   1  91  25   5   4   7 828   0]
 [ 2   0   1  10   0  11   0  17   1 958]]
```


重做之後發現準確率和 confusion matrix 沒變，不知道是我代碼的問題還是算法的問題，我明確確實實的把原始參數和新家的參數放了進去，我覺得訓練集的不同應該會有差異阿

以下是重做之後發現準確率和 confusion matrix


```
Cross-Validation Scores: [0.75881 0.68715 0.73772]
Mean Accuracy: 0.7278933333333333
Test Set Accuracy: 0.7365
```

Confusion Matrix:

```
[[ 648    4   11   313    5    2    7    0   10    0
   [  6 835    6 146    5    0    1    0    1    0
   [ 55    3 443 149 344    0    6    0    0    0
   [  8    4    1 974    8    0    3    0    2    0
   [  3    1   24 144 812    0   16    0    0    0
   [  4    0    0   19    0 881    0   65    8   23
   [174    2   67 297 338    0 108    0   14    0
   [  1    0    0    0    0   24    0 878    0   97
   [ 38    1    1   91   25    5    4    7 828    0
   [  2    0    1   10    0   11    0   17    1 958]]
```



左邊是原始的，右邊是資料加強後的



資料加強後的準確率甚至都是下降的，使我懷疑我的作法是錯誤的。`SGDClassifier` 的標準化或超參數調整，可以讓模型的準確率上升，但我感覺不如換一個 `Classifier`

以我的實驗去做結論的話，我認為 `SGDClassifier` 在第一個資料集上的效能比較好，在 `Fashion MNIST` 資料及上效果較差，而資料加強後再使用 `SGDClassifier` 在兩個資料集上都沒有取得更好的效果，在第一個資料集上資料加強效果較原始資料差一點，在第二個資料集上資料加強效果較原始資料差很多，我的結論是資料加強不一定帶來較好的性能，僅限於如果我的實驗是正確的，以上是功課一的報告內容，感謝觀看